

Trabajo práctico Unidad 3

1. Sobre este documento

Propósito

Este trabajo práctico tiene por objetivo acompañar a los estudiantes del curso Introducción a la Bioinformática en el proceso de análisis de datos obtenidos desde un secuenciador masivo. Se ofrece una guía de laboratorio para la ejecución del análisis paso a paso y las indicaciones para la construcción del reporte que resume el proceso.

Materiales y métodos

Se entregarán los resultados de la secuenciación Paired End en un equipo Illumina MiSeq de dos librerías (pacientes). Cada librería por tanto está compuesta por dos archivos FASTQ. Ambas corresponden a la secuenciación por amplicón del exoma del gen PKD1 humano, consistente de 51 exones y ubicado en 16p13.3. Adicionalmente, se deberá descargar la secuencia de referencia desde NCBI.

Las instrucciones de la guía de laboratorio asumen el uso de Ubuntu Linux, utilizando los programas: FastQC e IGV, y las utilidades desde línea de comandos trimmomatic, bwa, samtools, bcftools (instalables desde la línea de comandos con el comando `sudo apt install <utilidad>` o su equivalente en CONDA, `conda install -c bioconda <utilidad>`).

Entregable

Como entregable de este trabajo se realizará un informe, el cual debe ser entregado en formato PDF en la fecha indicada en la planificación del curso. Este reporte debe contener una explicación detallada del trabajo realizado de acuerdo a las indicaciones de la guía de laboratorio, incluyendo, entre otros, la explicación de los procesos, los comandos utilizados,

gráficas obtenidas, comentarios y conclusiones. La guía de laboratorio indicará expresamente qué se debe incluir en el informe en cuadros de texto como el siguiente:

Ingrese al reporte

- Una breve explicación sobre lo que se hizo
- Los comandos ingresados en la línea de comandos

2. Guía de Laboratorio

Inicio del Reporte

Es hora de comenzar su reporte, que irá creciendo a medida que avance en el trabajo. Se recomienda estructurarlo de forma similar a como se estructura esta guía de laboratorio.

Ingrese al reporte

- La portada, con el título del trabajo, los datos de la asignatura y los integrantes del grupo
- Una sección “Resumen”, que será escrita al final
- Defina aspectos de visualización: justificación de texto, formato de títulos, etc. Para lograr un reporte de aspecto profesional

Organización de directorios

La cantidad de archivos que irán generando a lo largo del proceso puede escalar rápidamente por lo que se recomienda contar con una estructura de directorios que mantenga el orden. Esta estructura debe considerar al menos la protección de los datos crudos (para evitar borrarlos o dañarlos accidentalmente) y las distintas etapas que se realizan durante el proceso de análisis.

Cree un directorio base para almacenar los archivos de su proyecto. Al interior del directorio base cree los siguientes directorios:

- **DNAref**, para almacenar el DNA de referencia
- **RawReads**, para almacenar los FASTQ obtenidos de la secuenciación (datos crudos)
- **FastQC_rawReads**, para almacenar los reportes de FastQC de los datos crudos
- **Trimmed_reads**, para almacenar los FASTQ podados
- **FastQC_trimmedReads**, para almacenar los reportes de FastQC de los datos podados

- **Aligned_reads**, para almacenar los archivos de alineamiento
- **Variant_calling**, para almacenar las variantes identificadas

Ingrese al reporte

- La descripción de los directorios

Descarga de archivos de base

En el directorio **RawReads** deje los archivos provistos. Dado que los archivos pueden tener nombres muy largos, lo que dificultará su identificación más adelante, se recomienda crear links simbólicos (con el comando `ln` de Linux) asignándoles nombres abreviados como `L2R1.fq.gz`, para nombrar al archivo que contiene los reads de la hebra positiva de la segunda librería, en formato FASTQ comprimido.

En el directorio **DNAref** deje el archivo FASTA que servirá de referencia para el alineamiento de los reads. Dado que trabajaremos con muestras provenientes de Humano, debemos descargar desde NCBI el FASTA de Homo sapiens (GRCh38). Considere que este archivo tiene un peso aproximado de 900 MB (FASTA comprimido)

Link directo: <https://www.ncbi.nlm.nih.gov/genome/?term=homo+sapiens>

Esta experiencia requiere que cuente con unos 3 GB libres en su computador. Si no tuviera a disposición estos recursos, también puede descargarse desde NCBI solo el FASTA del gen PKD1. Aparte de requerir menos espacio, esto acelerará los procesos de alineamiento.

No obstante, recuerde que el alineamiento se refiere a un archivo de referencia, por lo que si se alinea contra un FASTA más pequeño, las coordenadas del alineamiento y llamado de variantes no serán compatibles con la referencia y anotación de navegadores de genoma como IGV, los cuales se refieren al genoma completo.

Ingrese al reporte

- Una breve explicación sobre lo que se hizo

Control de Calidad

Los datos obtenidos durante la secuenciación contienen problemas de calidad, los cuales son reportados en el mismo archivo FASTQ. Es necesario podarlos (trimming) para proceder al alineamiento con datos de buena calidad.

A continuación se analizará la calidad de los datos con el programa FastQC, luego se podarán con trimmomatic, y luego se analizará la calidad de los datos podados nuevamente con FastQC, con el objeto de verificar su calidad y hacer la comparación con los datos crudos.

FastQC puede ser invocado desde la línea de comandos, lo que genera un output en HTML. Para ver cómo hacerlo tipee el siguiente comando:

```
$ <ruta_a_fastqc>/fastqc --help
```

El carácter \$ al inicio de la instrucción es el símbolo de la línea de comandos desplegada usualmente en Linux, no lo tipee. Respecto a la ruta indicada <entre_paréntesis>, reemplácela por la ruta al lugar en donde esté instalado el programa.

Invoque FastQC a través de la línea de comandos y deje los archivos de output en el directorio **FastQC_rawReads**.

Analice los resultados entregados por FastQC: ¿Cuántas lecturas componen cada archivo? ¿Cómo se comparan las calidades de R1 y R2? ¿Hay alguna característica destacable en los datos?

Ingrese al reporte

- Una breve explicación sobre lo que se hizo
- Los comandos ingresados en la línea de comandos
- Comentarios sobre los resultados, incluyendo imágenes de FastQC que respalden lo comentado (sea sintético, no ponga todos los gráficos si no va a decir algo sobre ellos)

Luego de haberse hecho una idea de la calidad de los datos, realice la poda con trimmomatic con los parámetros por defecto (ver clase sobre trimming).

Coloque los archivos de salida en el directorio **Trimmed_reads**, usando nombres cortos, tales como p_L2R1.fq.gz, indicando que se contienen las lecturas pareadas de R1 de la librería 2.

Una vez terminada la poda, considere arbitrariamente los archivos FASTQ correspondientes a únicamente a las lecturas pareadas. Repita el análisis con FastQC para estos archivos y compare con los archivos originales. ¿Qué porcentaje de las lecturas fueron retenidas? ¿Que efecto se observa en la calidad de los datos?

Ingrese al reporte

- Una breve explicación sobre lo que se hizo
- Los comandos ingresados en la línea de comandos
- Comentarios sobre los resultados, incluyendo imágenes de FastQC que respalden lo comentado

Alineamiento

El alineamiento requiere la indexación del genoma de referencia. Cree el índice del archivo FASTA almacenada en el directorio DNAREF y deje el índice en el mismo directorio (el índice se compone de varios archivos). Para hacerlo utilice la utilidad `index` de `bwa`. Para obtener ayuda tipee:

```
$ bwa index
```

O bien puede desplegar el manual del comando de la forma como se hace usualmente en Linux:

```
$ man bwa
```

Dependiendo de la longitud del FASTA, y de las características del computador en donde ejecute este proceso, la indexación puede tardar un buen rato (calcule al menos una hora para el genoma humano completo). Si desea conocer el tiempo que tomó el proceso, puede anteponer el comando `time` a cualquier comando que ejecute. Este comando reporta en un mensaje en la salida estándar el tiempo que demoró en ejecutarse el comando, sin afectar su funcionamiento.

Una vez creado el índice, se puede proceder al alineamiento de las secuencias PE que resultaron de la poda, almacenadas en el directorio **Trimmed_reads**. Para realizar el alineamiento utilice el comando `bwa mem`. El resultado del alineamiento (Archivo SAM/BAM) debe ser dirigido al directorio **Aligned_reads**.

Muchos archivos en bioinformática tienen una versión de texto y otra comprimida, con el objeto de hacerlos por una parte legibles y por otra manejables de forma más económica. Un algoritmo de compresión comúnmente utilizado en Linux (y por tanto en Bioinformática) es `gzip` (extensión `.gz`). Muchas utilidades bioinformáticas permiten procesar datos sin necesidad de descomprimirlos.

`bwa mem` puede generar un output en formato SAM o BAM. Cualquiera de estos dos formatos puede ser transformado en el otro utilizando el comando `samtools view`.

El archivo BAM puede ser desplegado en IGV para apreciar en qué posición del genoma de referencia se han alineado los reads. Para poder cargar el BAM, IGV requiere que esté indexado, y para indexarlo, requiere que esté ordenado. El ordenamiento se realiza con el comando `samtools sort` mientras que la indexación se realiza con el comando `samtools index`.

En IGV se debe procurar seleccionar el genoma de referencia adecuado, que debe coincidir con el que se utilizó para hacer el alineamiento. IGV tiene incorporado tanto la secuencia como

la anotación del genoma humano (GRCh38), por lo que los reads aparecerán alineados con los exones de PKD1. En caso de que se haya alineado contra un FASTA de PKD1 y no se cuente con el archivo de anotación del gen (BED o GFF), los reads aparecerán descontextualizados. Para cargar un FASTA propio como genoma de referencia, siga las instrucciones entregadas en <https://software.broadinstitute.org/software/igv/LoadGenome>.

Analice el alineamiento con ayuda de la visualización en IGV. ¿Cómo se distribuyen los reads sobre los exones? ¿Se observan a simple vista variantes estadísticamente significativas? ¿Las variantes son similares entre las dos librerías?

Ingrese al reporte

- Una breve explicación sobre lo que se hizo
- Los comandos ingresados en la línea de comandos
- Comentarios sobre los resultados, incluyendo imágenes de IGV que respalden lo comentado

Variant calling

Observando los reads alineados probablemente haya notado que hay una buena cantidad de variantes que no se repiten consistentemente y que con una alta probabilidad se refieren a artefactos. El llamado de variantes tiene por objeto identificar las variantes que con mayor probabilidad corresponden a mutaciones presentes en el ADN de los individuos secuenciados.

El llamado de variantes se puede realizar reuniendo los archivos BAM de diversas librerías (dos en nuestro caso). Para ser entregados a la línea de comandos, es necesario crear un archivo (en el directorio **Aligned_reads**) de texto con el nombre de los archivos BAM que se procesarán.

El llamado de variantes se divide en dos pasos. El primero contempla la creación de un archivo BCF intermedio (pileup), el que luego servirá de insumo al llamado propiamente tal.

La creación del archivo pileup se realiza con el comando `samtools mpileup`, y toma como argumentos el listado de los archivos BAM a procesar (archivo de texto) y el genoma de referencia (FASTA). Almacene el archivo BCF pileup resultante en el directorio **Variant_calling**.

`samtools mpileup` tiene problemas para trabajar con archivos comprimidos con gzip. Para superar este problema se puede utilizar un compresor similar (compatible con gzip), llamado **bgzip** (que también usa la extensión .gz). Para convertir el archivo FASTA comprimido con gzip a otro comprimido con bgzip, será necesario descomprimir el FASTA.gz (El DNA humano completo produce un FASTA descomprimido de 3.3 GB), y luego ser

comprimido utilizando bgzip mediante los siguientes comandos:

```
$ gunzip archivo.fna.gz  
$ bgzip archivo.fna
```

El llamado de variantes toma como input el archivo pileup generado, y genera un segundo BCF con las variantes identificadas.

Al igual que los archivos SAM y BAM pueden ser transformados uno en otro, los archivos BCF y VCF pueden ser convertidos con el comando `bcftools view`.

Una vez terminado el proceso de llamado de variantes, se pueden desplegar en IGV los datos más importantes del análisis: El genoma de referencia, los reads de ambas librerías y las variantes identificadas. Analice con la ayuda de IGV los resultados. ¿Cuántas variables se identificaron? ¿Alguna de ellas es común a las dos librerías? ¿Eran las que había detectado a simple vista? ¿En qué exones se ubican?

Ingrese al reporte

- Una breve explicación sobre lo que se hizo
- Los comandos ingresados en la línea de comandos
- Comentarios sobre los resultados, incluyendo imágenes de IGV que respalden lo comentado

Término del reporte

Si ha llegado a este punto, ¡felicitaciones!, el análisis ha concluído. Para generar un buen reporte, revise los pasos realizados anteriormente, y lo que ha ido consignando en el reporte hasta ahora, de manera de tener una visión global de todo el proceso. Con esta visión, escriba el resumen introductorio del reporte, y agregue una sección final con las conclusiones sobre lo aprendido. Posteriormente revise el informe completo para asegurarse que no tiene errores de ortografía, de presentación, que las ideas están expresadas claramente y en un orden que facilita la lectura. Finalmente genere una versión PDF y envíelo para revisión.

Ingrese al reporte

- Resumen y conclusiones sobre lo aprendido
- Correcciones de aspectos formales
- Genere versión en PDF y envíelo para revisión